

Toward Stable, Interpretable, and Lightweight Hyperspectral Super-resolution

莫子谦

摘要

在实际应用中, 现有的 HSI-SR 方法不仅在未知场景下性能不稳定, 而且计算量大。在本文中, 本文为稳定、可解释和轻量级的 HSI-SR 开发了一个新的协调优化框架。具体来说, 本文在一个新的概率框架下, 在融合与退化估计之间建立了一个正循环。估算出的降解应用于融合, 作为降解感知 HSI-SR 的指导。在这一框架下, 本文建立了一种明确的退化估计方法, 以解决以往方法中黑盒模拟造成的不确定性和性能不稳定问题。考虑到融合中的可解释性, 本文在融合过程中集成了频谱混合先验, 这可以通过一个很小的自动编码器轻松实现, 从而大大减轻了计算负担。在光谱混合先验的基础上, 本文还开发了部分微调策略, 以进一步降低计算成本。

关键词: 高光谱成像; 超分辨率; 稳定性; 可解释性; 轻量级

1 引言

与只有几个波段的传统光学图像不同, 具有几十到几百个波段的高光谱图像 (HSIs) 蕴含着有关物质的鉴别信息, 在生态系统、生物多样性和灾害监测与管理等广泛应用中具有巨大优势 [1–8]。然而, 成像的物理限制会导致空间和时间之间的权衡。然而, 成像的物理限制导致空间分辨率和光谱分辨率之间的权衡。在实际应用中, 高光谱成像存在空间分辨率低的问题。因此, 旨在提高 HSI 空间分辨率的高光谱超分辨率 (HSI-SR) 已成为一项重要任务, 并始终作为 HSI 应用 (即检测和分类) 的必要预处理 [9–16]。

由于常见的光学平台 (如卫星、机载平台) 都配备了高分辨率 HSI 传感器和多光谱传感器, 因此很容易获取同一场景中的 HSI 和多光谱图像 (MSI)。基于融合的 HSI-SR 旨在从相应的低分辨率 HSI (LR-HSI) 和高分辨率 MSI (HRMSI) 中估算出所需的高分辨率 HSI (HR-HSI)。

作为一项预处理任务, HSI-SR 面临两个挑战: 高保真恢复和高效处理 (即低计算负担和快速处理)。在本文中为稳定的、可解释的和轻量级的 HSI - SR 开发了一个新的协调优化框架。通过在 MAP 问题中融入 Wald 协议, 本文在先验和似然之间构建了一个正反馈回路。基于该框架, 本文探索了一种显式的退化估计, 以弥补黑箱估计性能不稳定的缺陷。对于先验, 本文建立了一个轻量级的自编码器来模拟高光谱图像中的光谱混合先验, 以实现可解释的融合。

2 相关工作

现有的高光谱超分辨率方法有很多局限性。首先，现有的方法通常基于黑盒子模拟，导致性能不稳定。其次，这些方法通常需要大量的计算资源，不适用于实际应用。最后，这些方法缺乏可解释性，难以理解和应用。为了解决这些问题，本文提出了一种新的高光谱超分辨率方法，该方法采用了协同优化框架，引入了光谱混合先验知识，并具有稳定性、可解释性和轻量级的特点。

2.1 HSI-SR 中的光谱混合先验

近期基于非混合的方法通过耦合自动编码器实现了光谱混合先验 [17–19]。观测到的 LR-HSI 和 HR-MSI 由两个自动编码器重构，以提取丰度（潜在特征）和内含物（解码器权重）。然后，LR-HSI 的解码器以 HR-MSI 的潜在特征为输入，生成 HR-HSI。这种方法有两个局限性。首先，LR-HSI 和 HR-MSI 的单独解混会导致对自动编码器特征分歧的特别敏感性。即使应用了一些修改方法，如交叉注意 [18] 和替代优化 [17]。其次，高维高光谱数据大大增加了耦合自动编码器的计算负担。相比之下，我们只用一个自编码器来模拟非混合先验，结果更准确，同时大大降低了计算复杂度。

2.2 退化估计

图像增强是一个典型的求解无穷的问题，因此迫切需要精确的退化估计来限制求解空间。模糊核的估计在单图像超分辨率 (SISR) 中，模糊核的估计成为一个热门话题。Wang 等人 [20] 提出了一种对比学习方案，用于在不同模糊核之间的相对距离下进行降级表示。Luo 等人 [21] 引入概率模型，建立了一个单一网络来映射模糊核的分布。在 [22] 中，利用各向异性高斯对模糊核建模，提出了一种显式退化估计方案。在 HSISR 中，Qu 等人 [17] 使用多个卷积层无监督地快速估计 PSF。Yao 等人 [18] 利用空间-光谱一致性对估计进行了正则化处理。在文献 [23] 中，只用了一个卷积层来模拟 PSF，结果更接近地面实况。SRF 是 HSI-SR 中的一种特殊退化。以往的方法通过 1×1 卷积层或全连接层对 SRF 进行建模 [17–19, 23, 24]。

2.3 Wald 协议

现实世界中无法获得与 HRMSI 具有相同空间分辨率的目标 HR-HSI。为了衡量 HSI-SR 方法的性能，Wald 协议表明，从降解的 HRMSI 和 LR-HSI 中恢复 LR-HSI 的性能与恢复未知 HR-HSI 的性能一致，这将降解和融合联系在了一起 [25]。

3 本文方法

3.1 本文方法概述

高空间分辨率高光谱图像超分辨 (HSI-SR) 问题被建模为具有参数 $\theta = \{C, R\}$ 和 ϕ 的最大后验 (MAP) 问题。然而，实际的退化参数 θ 和先验知识 ϕ 并非完全已知。本文提出了一个盲 HSI-SR 模型，其中包括对参数的额外推断，引入了无监督的退化估计。如公式 1 所示。

$$\max_{\mathcal{Z}, \theta, \phi} \log p(\mathcal{X}, \mathcal{Y} | \mathcal{Z}, \theta) + \log p(\mathcal{Z} | \mathcal{X}, \mathcal{Y}, \phi) + \log p(\phi | \mathcal{X}, \mathcal{Y}, \theta) + \log p(\theta | \mathcal{X}, \mathcal{Y}) \quad (1)$$

其中 $p(\theta|\mathcal{X}, \mathcal{Y})$ 表示在没有 HR-HSI 的指导下推断退化参数 θ ，从而实现无监督的退化估计。估计的退化量 θ 参与了融合模块 $p(\phi|\mathcal{X}, \mathcal{Y}, \theta)$ 的推理，限制了原始 MAP 模型进行协调优化的自由度。

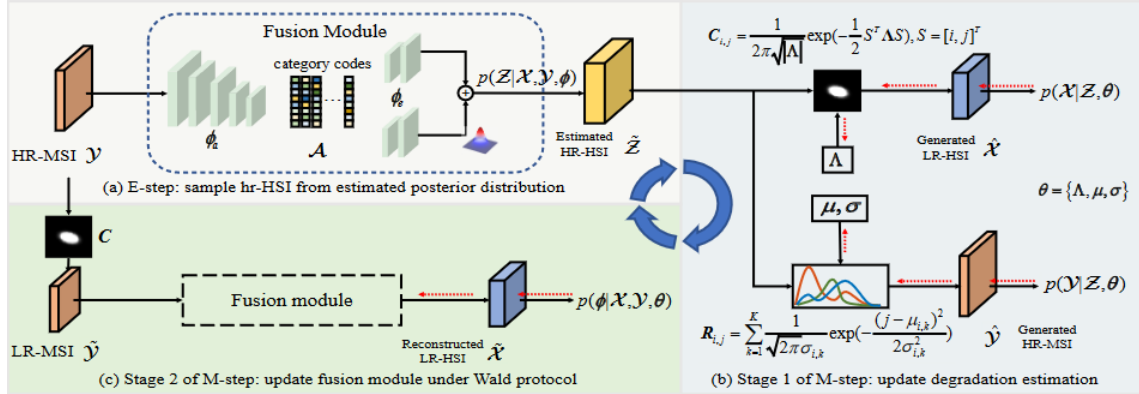


图 1. 整体框架

3.2 似然和先验之间的协同

本文基于 Wald 协议建立了似然和先验之间的协同。融合模块旨在从降级的低分辨率高光谱图像（LR-HSI）和高分辨率多光谱图像（HR-MSI）中恢复 LRHSI。该框架在退化估计和融合之间形成了良性循环，创造了一个强大的 HSI-SR，如以下公式所示。这种方法与退化估计和融合模块正交，易于集成以提高性能。

$$p(\phi|\mathcal{X}, \mathcal{Y}, \theta) = \prod_{i=1}^h \prod_{j=1}^w \mathcal{N}(\hat{\mathcal{X}}_{i,j}(\phi) | \mathbf{x}_{i,j}, \epsilon_1^2 I) \quad (2)$$

其中 $\hat{\mathcal{X}} = \mathcal{F}((\mathcal{X} * C) \downarrow_s, (\mathcal{Y} * C) \downarrow_s; \phi)$ ，此时，引导融合结果 $\mathcal{Z} = \mathcal{F}(\mathcal{X}, \mathcal{Y}; \phi)$ 将有利于退化参数的更新，即 $p(\mathcal{X}, \mathcal{Y} | \mathcal{Z}, \theta)$ 的最大值。

3.3 明确的退化估计

明确的退化估计着重于明确地捕捉退化的固有模式，以实现稳定而精确的估计。使用各向异性高斯核和混合高斯核点扩散函数（PSF）和光谱响应函数（SRF）进行建模。估计的退化参数形成似然函数，有助于整体优化。本文对 θ 的后验分布建模为：

$$p(\theta|\mathcal{X}, \mathcal{Y}) \propto \exp(-\|\mathcal{X} \times_3 R - (\mathcal{Y} * C) \downarrow_s\|^2) \quad (3)$$

其中 C 代表点扩散函数 PSF， R 代表光谱响应函数 SRF。

3.4 可解释和轻量级融合

融合模块被设计为可解释且轻量级。它模拟了高光谱成像中的光谱混合现象，采用了两阶段模型。第一阶段涉及用于检测材料类别的分类器，第二阶段利用微型自动编码器进行融合。融合模块反映了 HR-HSI 的物理生成过程，并在实际应用中计算高效。本文建立了一个两阶段模型来模拟 HSI 成像中的光谱混合现象：

$$\begin{aligned}\mathcal{A} &= \mathcal{D}(\mathcal{Y}; \phi_a), \\ \mathcal{Z} &= \mathcal{G}(\mathcal{A}; \phi_e) = \boldsymbol{\mu}(\mathcal{A}) + \boldsymbol{\sigma}(\mathcal{A}) \cdot \boldsymbol{\epsilon}, \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, I)\end{aligned}\tag{4}$$

其中 \mathcal{A} 是不同材料在 \mathcal{Z} 中的丰度。 $\mathcal{D}(\cdot)$ 是一个分类器，用于检测每个像素的材料类别，本质上 $\mathcal{G}(\cdot)$ 旨在从相应类别的材料中映射出每个高光谱向量。

4 复现细节

4.1 与已有开源代码对比

本文复现了作者所提出的稳定、可解释、轻量级的 DAEM 模型，并且对网络的 Fusion Module 模块进行了修改。在原始网络的 Fusion Module 模块中丰度估计采用的是 HR-MSI 的残差连接，为了更有效地传播梯度，减轻梯度消失的问题，我们将残差连接改为了密集连接，本实验也验证了作者所提出模型的有效性。

4.2 实验环境搭建

表 1. 服务器配置详情

| | |
|-----|----------------------------------|
| CPU | 12 \times <i>XeonGold</i> 6271 |
| GPU | NVIDIA Tesla P100-16GB |
| 显存 | 16GB |
| 内存 | 48GB |
| 硬盘 | 200GB |

4.3 实验过程

我们在 Pytorch 下使用单个 P-100 实现了我们的方法。我们在训练阶段应用 ADAM 优化器，参数 $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\eta = 10^{-8}$ 。训练和微调阶段的学习率分别初始化为 10^{-3} 和 5×10^{-3} 。训练阶段采用 100 个 epoch，测试阶段采用 250 个 epoch。实验选用的数据集为 CAVE 数据集，CAVE 数据集包含 32 个来自不同室内场景的 HSIs 成像。每个 HSI 包含 512×512 个像素，在 400nm 到 700nm 的波长范围内测量 31 个光谱波段。

4.4 创新点

为了更好地提取特征，将原论文中 Fusion Module 模块中丰度估计采用的残差连接改成了密集连接，让每一层都能够充分地利用前一层的信息，使得网络更好地适应任务需求。相比残差连接，密集连接能够更灵活地学习输入和输出之间的复杂映射关系。每个节点都可以对应到更细致的特征，有助于网络学习更为丰富的特征表示，同时还能缓解梯度消失。




图 2. 原文残差连接示意图




图 3. 改进密集连接示意图

5 实验结果分析

我们采用四种图像质量指数 (PQIs) 进行定量评价

- 峰值信噪比 PSNR。衡量最大值信号和背景噪音之间的差异。定义公式如下

$$\text{PSNR}(\mathcal{X}, \hat{\mathcal{X}}) = 10 \lg \left(\frac{\max(\mathbf{X}_i)^2}{\frac{1}{HW} \|\mathbf{X}_i - \hat{\mathbf{X}}_i\|^2} \right), \quad (5)$$

- 光谱角制图 SAM。SAM 衡量重构 HR-HSI 中每个高光谱像元的光谱扭曲程度。

$$\text{SAM}(\mathcal{X}, \hat{\mathcal{X}}) = \frac{1}{HW} \sum_{i=1}^{HW} \cos^{-1} \left(\frac{\mathbf{x}_i^T \hat{\mathbf{x}}_i}{\|\mathbf{x}_i\|_2 \|\hat{\mathbf{x}}_i\|_2} \right) \quad (6)$$

- 相对光谱信息熵全局精度 ERGAS，ERGAS 考虑 HR-MSI 和 LR-HSI 之间的地面样本距离的比值来衡量重建 HR-HSI 的全局统计质量。

$$\text{ERGAS}(\mathcal{X}, \hat{\mathcal{X}}) = \frac{100}{c} \sqrt{\frac{1}{B} \sum_{i=1}^B \frac{\text{MSE}(\mathbf{X}_i, \hat{\mathbf{X}}_i)}{\mu_{\hat{\mathbf{X}}_i}^2}} \quad (7)$$

- 通用图像质量指标 UIQI。

$$\text{UIQI} = \frac{\sigma(\mathbf{X}\hat{\mathbf{X}})}{\sigma(\mathbf{X})\sigma(\hat{\mathbf{X}})} \cdot \frac{2\mu(\mathbf{X}\hat{\mathbf{X}})}{(\mu(\mathbf{X})^2 + \mu(\hat{\mathbf{X}})^2)} \cdot \frac{2\sigma(\mathbf{X})\sigma(\hat{\mathbf{X}})}{(\sigma(\mathbf{X})^2 + \sigma(\hat{\mathbf{X}})^2)} \quad (8)$$

表 2. 测试方法在 CAVE 数据集上的平均性能

| Dataset CAVE | | | | | |
|--------------|-------|------|-------|-------|--------|
| Methods | PSNR | SAM | ERGAS | UIQI | params |
| Ours | 39.50 | 6.74 | 0.340 | 0.944 | 6558 |
| Ours(dense) | 39.85 | 6.87 | 0.333 | 0.944 | 7990 |

我们选择了 CAVE 数据集中头发场景第 15 个波段的图像进行结果展示，并计算了各自的误差图像，视觉检查表明，与本文方法相比，我们的改进方法具有更清晰的纹理。

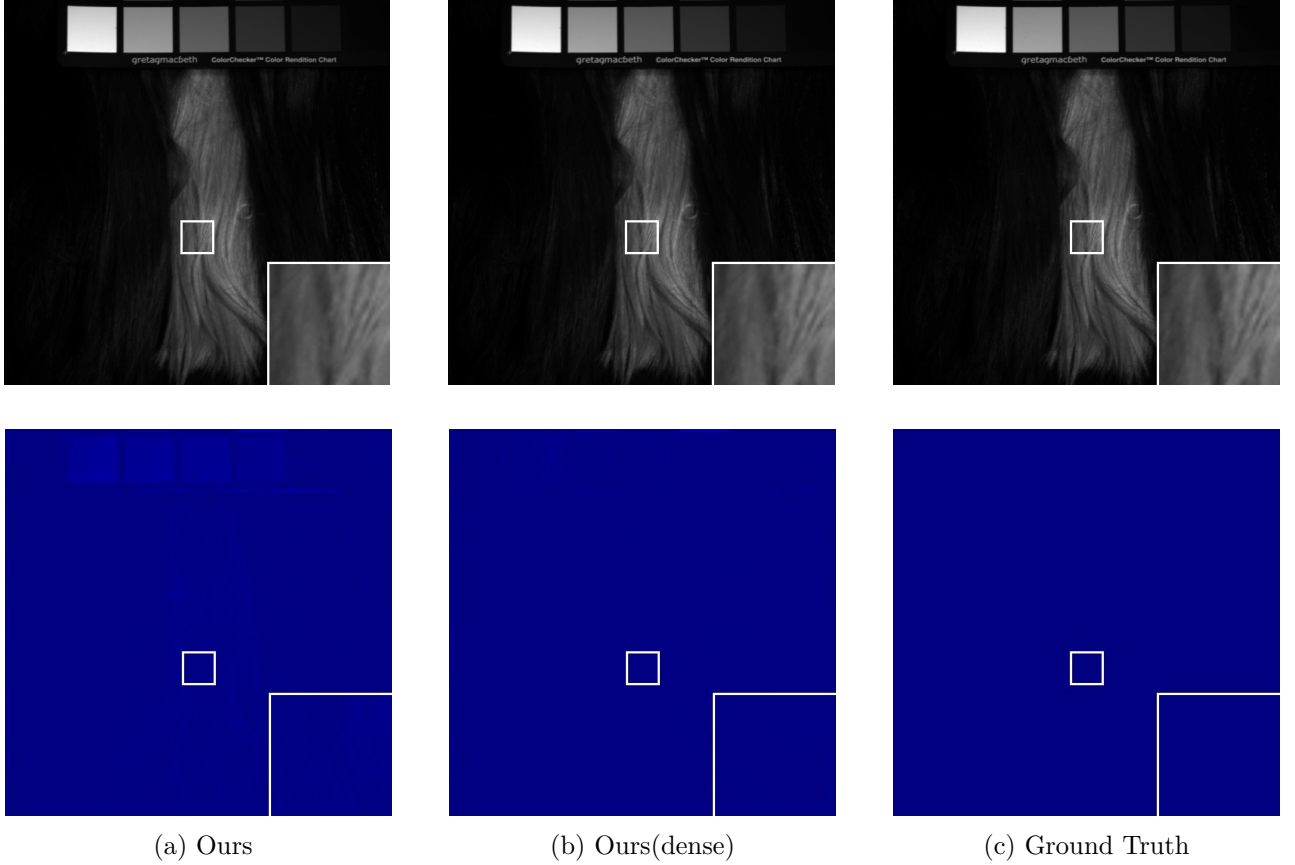


图 4. CAVE 数据集中头发场景第 15 波段的超分辨率结果和相应的误差图像

我们通过随机抽取两个位置的光谱波段，对于本文方法、改进方法以及真实值进行了光谱信息的比较。观察结果表明，改进后的光谱信息更为接近真实值，这表明我们改进的方法在高光谱图像融合超分上取得了一定的改进。这进一步证实了我们的研究对于光谱信息的精确捕捉和重建具有卓越的能力。

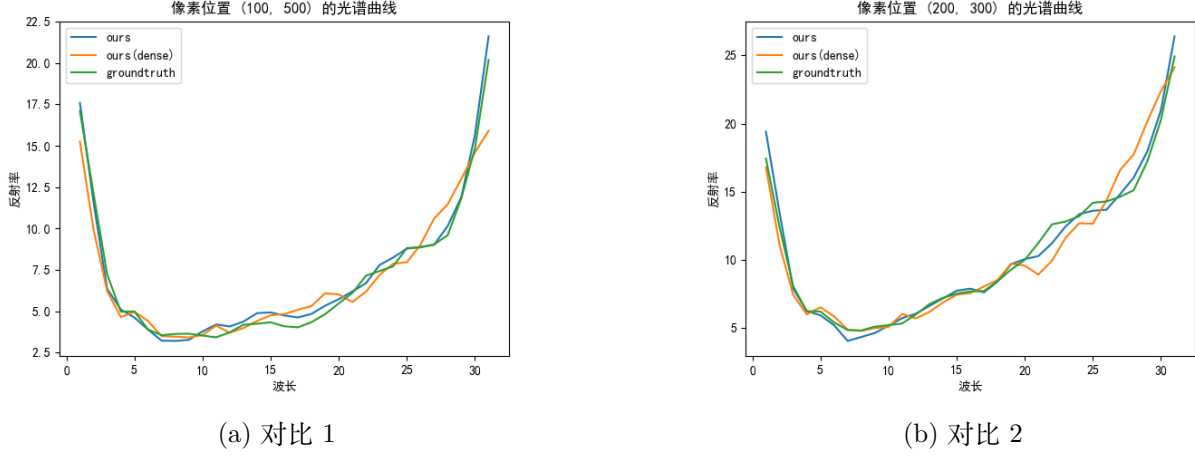


图 5. 论文方法、改进方法以及 Ground Truth 的光谱信息差异

6 总结与展望

本文开发了一个协调优化的 HSI-SR 框架，在退化估计和融合之间建立了一个虚拟的循环。在该框架下，本文进一步探索了一种性能稳定的显式退化估计策略。同时，本文建立了一个在光谱混合先验下的微型自编码器，用于可解释性和轻量级的融合。生成了六种不同的 PSF 来验证我们的方法在各种退化的未知场景下的效率和稳定性。为了更好地提取特征，我们将本文中 Fusion Module 中丰度估计采用的残差连接改成了密集连接，让每一层都能够充分地利用前一层的的信息，使得网络更好地适应任务需求。综合实验表明，我们的框架虽然在增加了参数量，但在准确性指标比原论文有一定的提高。我们在未来的工作中留下了两个研究方向，包括在真实世界设备上的实现和在图像增强中扩展到更多的任务。

参考文献

- [1] Jose M. Bioucas-Dias, Antonio Plaza, Gustavo Camps-Valls, Paul Scheunders, Nasser Nasrabadi, and Jocelyn Chanussot. Hyperspectral remote sensing data analysis and future challenges. *IEEE Geoscience and Remote Sensing Magazine*, 1(2):6–36, 2013.
- [2] Lujendra Ojha, Mary Beth Wilhelm, Scott L Murchie, Alfred S McEwen, James J Wray, Jennifer Hanley, Marion Massé, and Matt Chojnacki. Spectral evidence for hydrated salts in recurring slope lineae on mars. *Nature Geoscience*, 8(11):829–832, 2015.
- [3] Ying Fu, Antony Lam, Yasuyuki Kobashi, Imari Sato, Takahiro Okabe, and Yoichi Sato. Reflectance and fluorescent spectra recovery based on fluorescent chromaticity invariance under varying illumination. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2014.
- [4] Ying Fu, Antony Lam, Imari Sato, Takahiro Okabe, and Yoichi Sato. Separating reflective and fluorescent components using high frequency illumination in the spectral domain. In

Proceedings of the IEEE International Conference on Computer Vision (ICCV), December 2013.

- [5] Bing Lu, Phuong D. Dao, Jiangui Liu, Yuhong He, and Jiali Shang. Recent advances of hyperspectral imaging technology and applications in agriculture. *Remote Sensing*, 12(16), 2020.
- [6] A-K Mahlein, Matheus T Kuska, Jan Behmann, Gerrit Polder, and Achim Walter. Hyperspectral sensors and imaging technologies in phytopathology: state of the art. *Annual review of phytopathology*, 56:535–558, 2018.
- [7] Guolan Lu and Baowei Fei. Medical hyperspectral imaging: a review. *Journal of biomedical optics*, 19(1):010901–010901, 2014.
- [8] Pedram Ghamisi, Naoto Yokoya, Jun Li, Wenzhi Liao, Sicong Liu, Javier Plaza, Behnood Rasti, and Antonio Plaza. Advances in hyperspectral image and signal processing: A comprehensive overview of the state of the art. *IEEE Geoscience and Remote Sensing Magazine*, 5(4):37–78, 2017.
- [9] Shutao Li, Weiwei Song, Leyuan Fang, Yushi Chen, Pedram Ghamisi, and Jon Atli Benediktsson. Deep learning for hyperspectral image classification: An overview. *IEEE Transactions on Geoscience and Remote Sensing*, 57(9):6690–6709, 2019.
- [10] Xiao Xiang Zhu, Devis Tuia, Lichao Mou, Gui-Song Xia, Liangpei Zhang, Feng Xu, and Friedrich Fraundorfer. Deep learning in remote sensing: A comprehensive review and list of resources. *IEEE geoscience and remote sensing magazine*, 5(4):8–36, 2017.
- [11] Hien Van Nguyen, Amit Banerjee, and Rama Chellappa. Tracking via object reflectance using a hyperspectral video camera. In *2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition-Workshops*, pages 44–51. IEEE, 2010.
- [12] Yuliya Tarabalka, Jocelyn Chanussot, and Jón Atli Benediktsson. Segmentation and classification of hyperspectral images using minimum spanning forest grown from automatically selected markers. *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, 40(5):1267–1279, 2009.
- [13] Qi Wang, Jianzhe Lin, and Yuan Yuan. Salient band selection for hyperspectral image classification via manifold ranking. *IEEE transactions on neural networks and learning systems*, 27(6):1279–1289, 2016.
- [14] Burak Uzkent, Matthew J Hoffman, and Anthony Vodacek. Real-time vehicle tracking in aerial video using hyperspectral features. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops*, pages 36–44, 2016.

- [15] Burak Uzcent, Aneesh Rangnekar, and Matthew Hoffman. Aerial vehicle tracking by adaptive fusion of hyperspectral likelihood maps. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops*, pages 39–48, 2017.
- [16] Yunsong Li, Weiyang Xie, and Huaqing Li. Hyperspectral image reconstruction by deep convolutional neural network for classification. *Pattern Recognition*, 63:371–383, 2017.
- [17] Ying Qu, Hairong Qi, and Chiman Kwan. Unsupervised sparse dirichlet-net for hyperspectral image super-resolution. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 2511–2520, 2018.
- [18] Jing Yao, Danfeng Hong, Jocelyn Chanussot, Deyu Meng, Xiaoxiang Zhu, and Zongben Xu. Cross-attention in coupled unmixing nets for unsupervised hyperspectral super-resolution. In *Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXIX 16*, pages 208–224. Springer, 2020.
- [19] Lei Zhang, Jiangtao Nie, Wei Wei, Yanning Zhang, Shengcai Liao, and Ling Shao. Unsupervised adaptation learning for hyperspectral imagery super-resolution. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 3073–3082, 2020.
- [20] Longguang Wang, Yingqian Wang, Xiaoyu Dong, Qingyu Xu, Jungang Yang, Wei An, and Yulan Guo. Unsupervised degradation representation learning for blind super-resolution. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10581–10590, 2021.
- [21] Zhengxiong Luo, Yan Huang, Shang Li, Liang Wang, and Tieniu Tan. Learning the degradation distribution for blind image super-resolution. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 6063–6072, 2022.
- [22] Zongsheng Yue, Qian Zhao, Jianwen Xie, Lei Zhang, Deyu Meng, and Kwan-Yee K Wong. Blind image super-resolution with elaborate degradation modeling on noise and kernel. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2128–2138, 2022.
- [23] Ke Zheng, Lianru Gao, Wenzhi Liao, Danfeng Hong, Bing Zhang, Ximin Cui, and Jocelyn Chanussot. Coupled convolutional neural network with adaptive response function learning for unsupervised hyperspectral super resolution. *IEEE Transactions on Geoscience and Remote Sensing*, 59(3):2487–2502, 2020.
- [24] Ying Fu, Tao Zhang, Yinqiang Zheng, Debing Zhang, and Hua Huang. Hyperspectral image super-resolution with optimized rgb guidance. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11661–11670, 2019.

- [25] Lucien Wald. *Data fusion: definitions and architectures: fusion of images of different spatial resolutions*. Presses des MINES, 2002.